

Distribución Normal

Trabajo Práctico

Asignatura: Analítica de datos

Estudiante: Juliana Hernández

Fecha: 18 de septiembre de 2026

Universidad Católica del Uruguay

Campus Punta del Este

Resumen

Resumen

En este informe se analiza una base de datos compuesta por 1000 observaciones numéricas, utilizando herramientas de Python mediante Google Colab. En primer lugar, se verificó la estructura de los datos y la ausencia de valores nulos, y posteriormente se realizó un análisis estadístico descriptivo para obtener medidas como la media, la desviación estándar, los valores mínimo y máximo y los cuartiles. A partir de los datos se obtuvo una media de 49,55 y una desviación estándar de 9,88. Luego, se realizó la tipificación de las observaciones mediante el cálculo de valores Z y se representaron gráficamente tanto los datos originales como los valores tipificados. Finalmente, se utilizó la distribución normal para calcular probabilidades, tomando como referencia el valor $X = 60$, cuyo valor tipificado fue aproximadamente $Z = 1,0585$, obteniéndose una probabilidad acumulada de $P(X \leq 60) = 0,8551$. El análisis permitió relacionar conceptos de probabilidad y estadística con herramientas de programación para el procesamiento, visualización e interpretación de datos.

Índice

1. Introducción	1
2. Desarrollo	1
2.1. Carga, Verificación y Forma de la Base de Datos	1
2.2. Análisis Descriptivo	2
2.3. Tipificación de los Datos	3
2.4. Gráficos de Distribución	3
2.5. Cálculos de Probabilidades	4
3. Conclusión	5
4. Referencias	5

1. Introducción

En el estudio de la probabilidad y la inferencia estadística, existen diversos modelos matemáticos diseñados para describir el comportamiento de fenómenos aleatorios. Entre ellos, la distribución normal constituye uno de los modelos de probabilidad más utilizados, debido a su aplicación en numerosos contextos científicos, económicos y de ingeniería [1].

La distribución normal es una distribución continua caracterizada por su forma de campana, simétrica respecto de su media. Su comportamiento queda determinado principalmente por dos parámetros: la media, que representa el centro de la distribución, y la desviación estándar, que indica el grado de dispersión de los datos respecto de dicho centro [2].

En el presente trabajo se analiza una base de datos compuesta por 1000 observaciones numéricas. A partir de estos datos se calculan medidas estadísticas descriptivas, como la media y la desviación estándar, y posteriormente se estudia su comportamiento mediante la distribución normal.

Un aspecto importante del análisis es que la media utilizada no fue establecida previamente como un valor fijo, sino que se obtuvo a partir de los propios datos de la base. De esta manera, los parámetros utilizados para el análisis surgen de las características observadas en el conjunto de datos.

Además, se realiza la tipificación de las observaciones mediante el cálculo de valores Z , lo que permite expresar cada dato en función de cuántas desviaciones estándar se encuentra respecto de la media. Finalmente, se utilizan herramientas de Python para calcular probabilidades asociadas a la distribución normal.

2. Desarrollo

El presente análisis se llevó a cabo utilizando un entorno de programación en Python mediante Google Colab, empleando librerías especializadas como `pandas`, `numpy`, `matplotlib` y `scipy.stats`. El trabajo consistió en procesar y analizar una base de datos con valores numéricos almacenados en un archivo CSV.

2.1. Carga, Verificación y Forma de la Base de Datos

En primer lugar, se estableció la conexión con Google Drive para importar el archivo CSV que contenía los datos. Para comprender la estructura general de la información, se utilizaron funciones de la librería `pandas`.

- `df.shape`: permitió conocer las dimensiones de la base de datos, obteniendo un total de 1000 filas y 1 sola columna.

- `df.head()`: se utilizó para visualizar los primeros registros de la base de datos y comprobar el formato de los valores.
- `df.isnull().sum()`: se aplicó para verificar la existencia de valores nulos o vacíos. El resultado fue de 0 valores nulos.

La base de datos presenta, por lo tanto, 1000 observaciones numéricas distribuidas en una única variable denominada **Valores**.

A continuación, la Tabla 1 muestra una muestra de los primeros registros obtenidos mediante `df.head()`:

Índice	Valores
0	67.64
1	54.00
2	59.79
3	72.41
4	68.68

Cuadro 1: Primeros valores de la base de datos.

2.2. Análisis Descriptivo

Una vez verificada la estructura de la base de datos, se realizó un análisis estadístico descriptivo mediante la función `df.describe()`. Esta función permite obtener diferentes medidas de resumen de las observaciones.

Los principales resultados obtenidos fueron:

- **Conteo (count)**: se registraron 1000 observaciones.
- **Media (mean)**: se obtuvo un valor de 49,55. Esta media fue calculada a partir de los valores presentes en la base de datos y no fue establecida previamente como un parámetro fijo.
- **Desviación estándar (std)**: se obtuvo un valor de 9,88, lo que permite medir la dispersión de las observaciones respecto de la media.
- **Valor mínimo y máximo**: el valor mínimo registrado fue 19,54, mientras que el valor máximo fue 77,59.
- **Cuartiles**: el primer cuartil (25 %) fue 43,02, la mediana (50 %) fue 49,42 y el tercer cuartil (75 %) fue 56,07.

La cercanía entre la media (49,55) y la mediana (49,42) permite observar que los datos presentan una distribución aproximadamente simétrica alrededor de su valor central.

2.3. Tipificación de los Datos

Posteriormente, se realizó la tipificación de los datos mediante la creación de una nueva columna denominada **Valores Tipificados**.

La tipificación permite determinar la posición relativa de cada observación respecto de la media, expresándola en unidades de desviación estándar. Para ello se utilizó la siguiente expresión:

$$Z = \frac{X - \mu}{\sigma}$$

donde X representa el valor observado, μ corresponde a la media y σ representa la desviación estándar.

De esta manera, un valor de $Z = 0$ representa una observación igual a la media, mientras que un valor positivo indica que la observación se encuentra por encima de la media y un valor negativo indica que se encuentra por debajo.

La tipificación permite trabajar con una escala estandarizada cuya media es aproximadamente 0 y cuya desviación estándar es aproximadamente 1. Esto facilita la comparación de las posiciones relativas de las diferentes observaciones.

2.4. Gráficos de Distribución

Con el objetivo de visualizar el comportamiento de los datos, se generaron dos gráficos mediante la librería `matplotlib`.

- **Gráfico de Distribución Normal:** se construyó un histograma utilizando los 1000 valores de la base de datos, empleando 30 intervalos (*bins*) y representando la densidad de las observaciones. Sobre el histograma se superpuso una curva normal calculada utilizando como parámetros la media y la desviación estándar obtenidas de los datos.




Figura 1: Gráfico de la distribución normal.

El gráfico permite observar una concentración de los datos alrededor de la media de 49,55, con una forma aproximadamente simétrica y una disminución de la densidad hacia los extremos.

- **Gráfico de Distribución Tipificada:** se representó la misma información después de realizar la tipificación de los datos. En este caso, el eje horizontal corresponde a los valores Z , permitiendo interpretar las observaciones según la cantidad de desviaciones estándar que las separan de la media.




Figura 2: Gráfico de la distribución tipificada.

2.5. Cálculos de Probabilidades

Para finalizar el análisis, se realizaron cálculos de probabilidad utilizando las funciones `norm.cdf` y `norm.ppf` de la librería `scipy.stats`.

Se tomó como referencia el valor original:

$$X = 60$$

Utilizando la media y la desviación estándar obtenidas de la base de datos, se calculó su correspondiente valor tipificado:

$$Z = \frac{60 - 49,5474}{9,8753} \approx 1,0585$$

Esto significa que el valor 60 se encuentra aproximadamente 1,06 desviaciones estándar por encima de la media.

A continuación, se calculó mediante la función `norm.cdf` la probabilidad acumulada correspondiente al valor $X = 60$:

$$P(X \leq 60) = 0,8551$$

Por lo tanto, según el modelo de distribución normal utilizado, la probabilidad acumulada de obtener un valor menor o igual a 60 es de aproximadamente 85,51 %.

El mismo resultado puede expresarse mediante la distribución normal estándar utilizando el valor tipificado obtenido:

$$P(Z \leq 1,0585) \approx 0,8551$$

De esta manera, se comprueba que la probabilidad calculada en la distribución original y la probabilidad correspondiente en la distribución tipificada son equivalentes.

3. Conclusión

A lo largo de este informe se aplicaron herramientas de programación en Python para analizar una base de datos mediante conceptos asociados a la distribución normal.

En primer lugar, la verificación de la base de datos permitió comprobar que se contaba con 1000 observaciones y que no existían valores nulos. Posteriormente, mediante el análisis descriptivo se obtuvo una media de aproximadamente 49,55 y una desviación estándar de aproximadamente 9,88. Estos valores fueron calculados a partir de los datos disponibles y no establecidos previamente como parámetros fijos.

El análisis de los cuartiles y la comparación entre la media y la mediana permitieron observar una distribución aproximadamente simétrica de los datos alrededor de su valor central.

Asimismo, la tipificación permitió expresar las observaciones en términos de desviaciones estándar respecto de la media. Esta transformación facilita el análisis de la posición relativa de los datos y permite trabajar con una escala estandarizada.

Finalmente, utilizando las funciones de `scipy.stats`, se calculó la probabilidad acumulada correspondiente al valor $X = 60$. El resultado obtenido fue $P(X \leq 60) = 0,8551$, equivalente a una probabilidad del 85,51 % según el modelo normal utilizado. El mismo resultado se obtuvo al trabajar con el valor tipificado $Z \approx 1,0585$.

Este ejercicio permitió relacionar los conceptos de estadística y probabilidad con herramientas de programación, mostrando cómo Python y sus librerías especializadas pueden facilitar el procesamiento, la visualización y el análisis de datos.

4. Referencias

Referencias

- [1] Walpole, R. E., Myers, R. H., Myers, S. L., y Ye, K. (2012). *Probabilidad y estadística para ingeniería y ciencias* (9ª ed.). Pearson Educación.

- [2] Devore, J. L. (2016). *Probabilidad y estadística para ingeniería y ciencias* (9ª ed.). Cengage Learning.